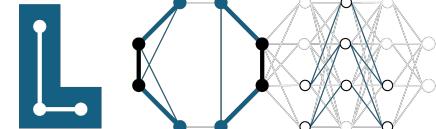


Ciencia y Tecnología

Secretaría de Ciencia, Humanidades,
Tecnología e Innovación



Laboratorio de Ciencia de Datos y Aprendizaje Automático

Curso IA desde Cero

Dr. Irvin Hussein López Nava
M.C. Joan M. Raygoza Romero

Departamento de Ciencias de la Computación
Centro de Investigación Científica y de Educación Superior de Ensenada
Edición 2025

CURSO VIRTUAL

IA desde Cero:
Un Curso Práctico

EDUCACIÓN CONTINUA | FÍSICA APLICADA | CICESE

Del 3 de Nov
al 1 de Dic

Dirigido al Público en general,
que desee aprender técnicas de IA.



Duración: 18 horas

Horario: Lunes y miércoles,
5:00 p.m. - 7:00 p.m.

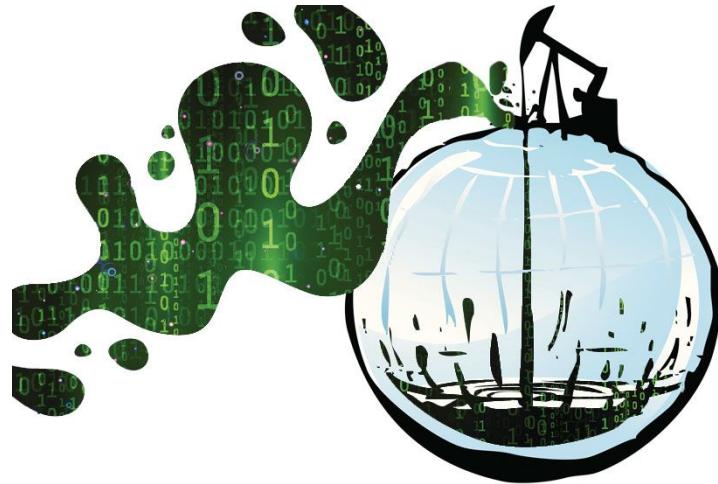


Recursos

SCAN ME



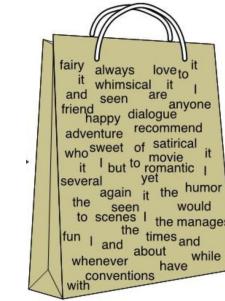
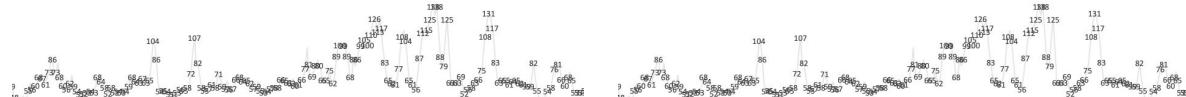
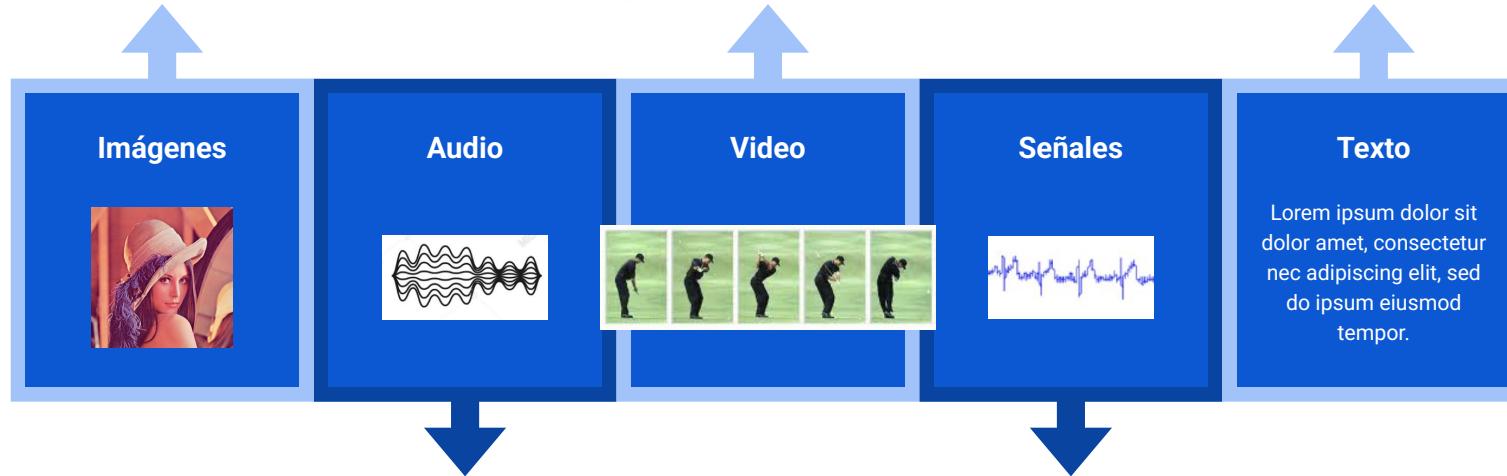
Datos



```

0 2 15 0 0 11 10 0 0 0 0 9 9 9 0 0 0
0 0 0 4 60 157 236 255 255 177 95 61 32 0 0 29
0 10 16 119 238 255 244 245 243 250 249 255 222 103 10 0
0 14 170 255 255 244 254 255 253 245 255 249 253 251 124 1
2 98 255 228 255 261 254 211 141 116 122 215 251 238 255 49
13 217 243 255 155 33 226 62 2 0 10 13 232 255 36
16 229 252 254 49 12 0 0 7 7 0 70 237 252 235 62
6 141 245 255 212 25 11 9 3 0 115 236 243 255 137 0
0 87 252 250 248 215 60 0 1 121 252 255 248 144 6 0
0 13 113 255 255 245 255 182 181 248 252 242 208 36 0 19
1 0 5 117 251 255 241 255 247 255 241 162 17 0 7 0
0 0 0 4 58 251 255 246 254 253 255 120 11 0 1 0
0 0 4 97 255 255 255 248 252 255 244 255 182 10 0 4
0 22 206 252 246 251 241 100 24 113 255 245 255 194 9 0
0 111 255 242 255 158 20 0 0 6 39 255 232 230 56 0
0 218 251 250 137 7 11 0 0 0 2 62 255 250 125 3
0 173 255 255 101 9 20 0 13 3 13 182 251 245 61 0
0 107 251 241 255 230 98 55 19 118 217 248 253 255 52 4
0 18 146 250 255 247 255 255 255 249 255 240 255 129 0 5
0 0 23 113 215 255 250 248 255 255 248 248 118 14 12 0
0 0 6 1 0 52 153 233 255 252 147 37 0 0 4 1
0 0 5 5 0 0 0 0 0 14 1 0 6 6 0 0 0

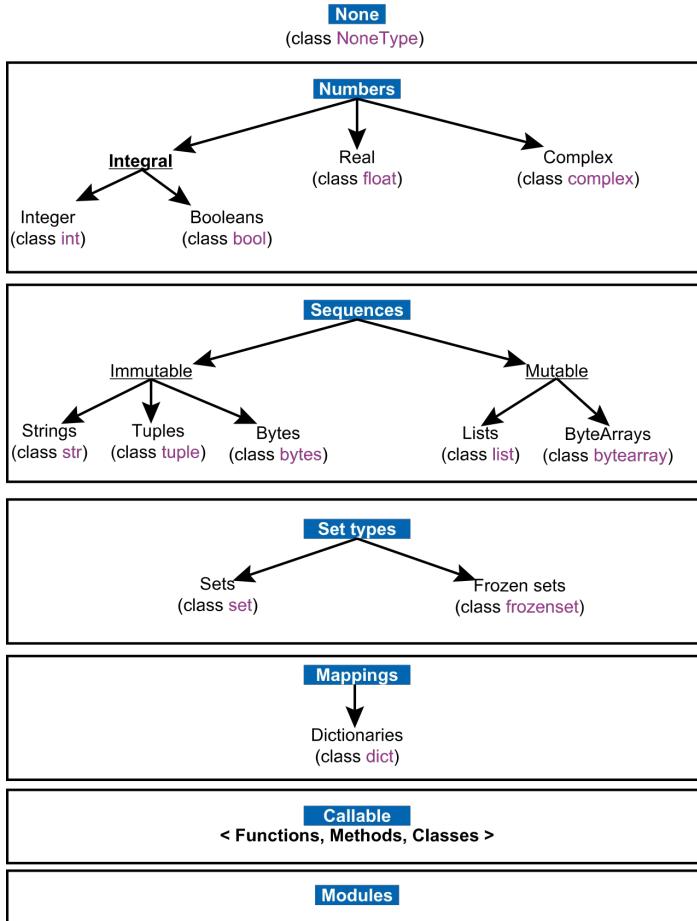
```



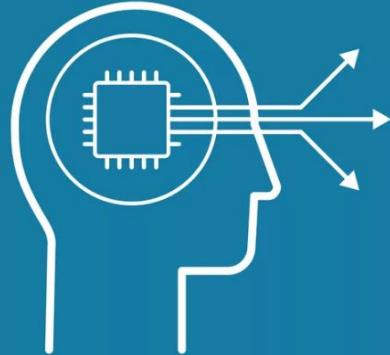
it
I
the
and
seen
yet
would
whimsical
times
sweet
satirical
adventure
genre
fairy
humor
have
great
...

Datos en Python

Python 3
The standard type hierarchy



1950



ARTIFICIAL INTELLIGENCE

ENGINEERING OF MACHINES
THAT MIMIC COGNITIVE FUNCTIONS

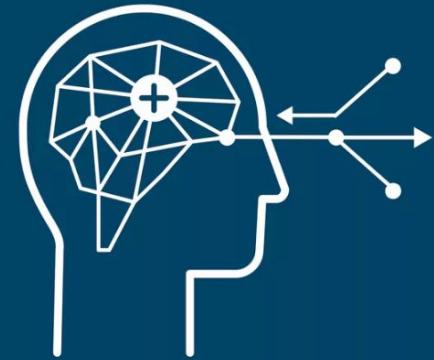
1980



MACHINE LEARNING

ABILITY TO PERFORM TASKS
WITHOUT EXPLICIT INSTRUCTIONS
AND RELYING ON PATTERNS

2010



DEEP LEARNING

MACHINE LEARNING BASED
ON ARTIFICIAL NEURAL NETWORKS

¿Qué nos interesa más ahora?

Aprendizaje
automático

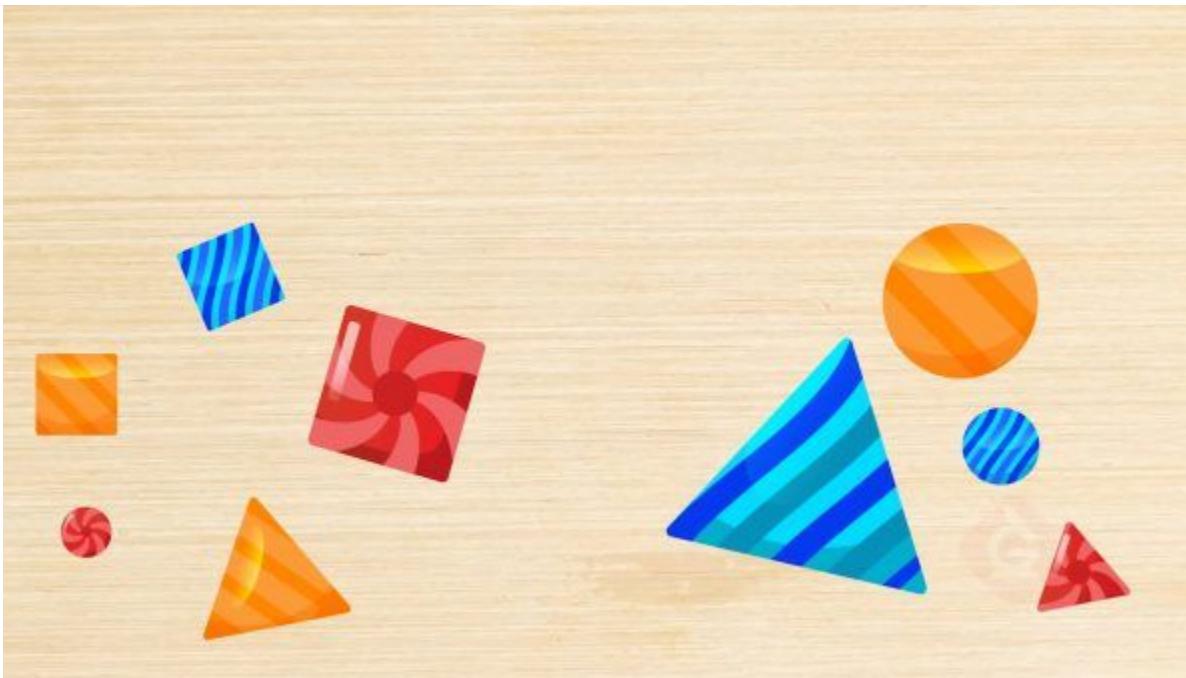


Obj:

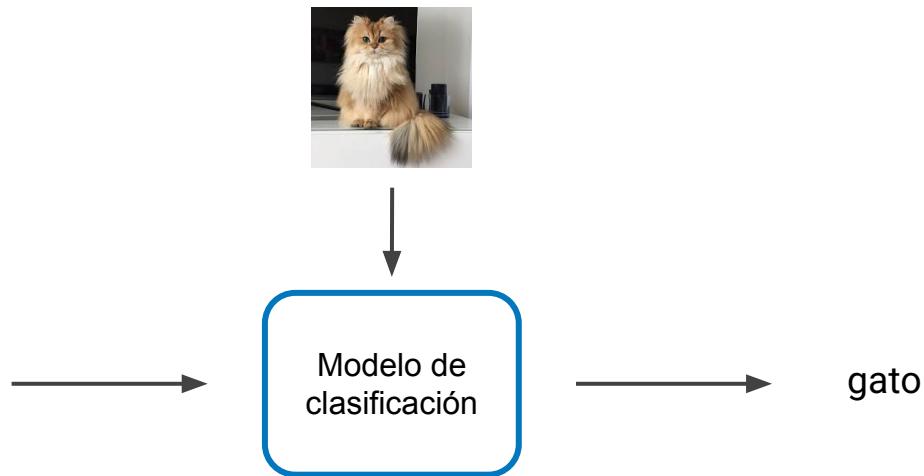
Modelos predictivos

Reconocimiento de patrones/estructuras

Clasificación natural



Un primer caso

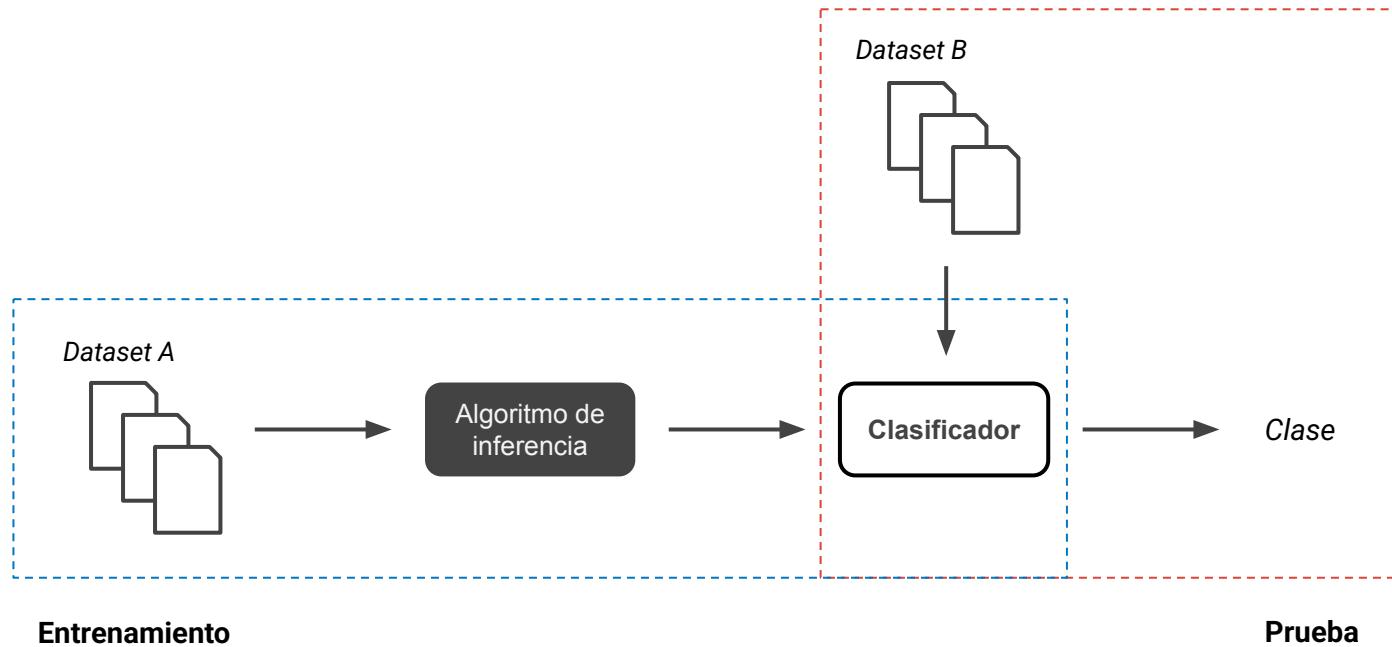


¿Qué es clasificación?

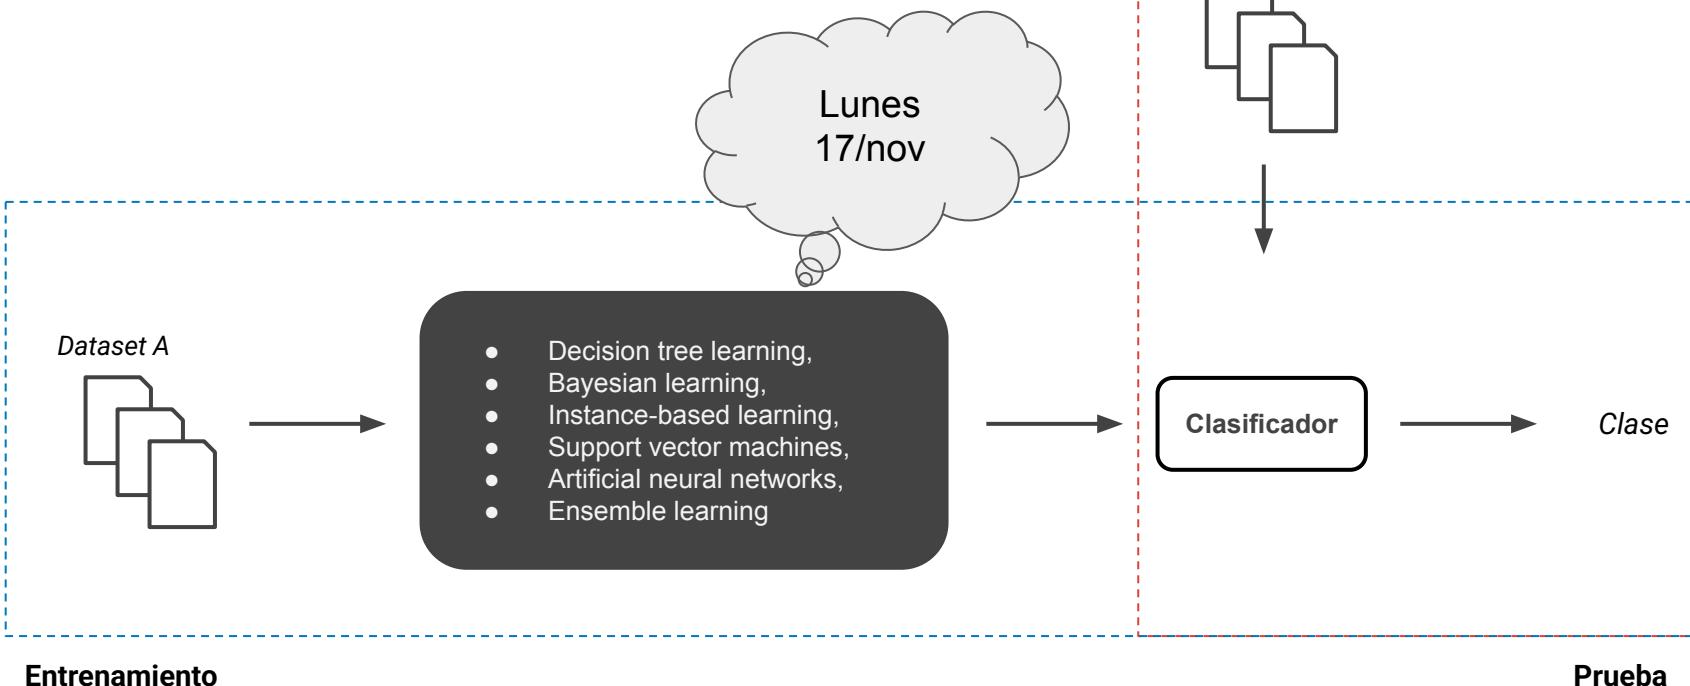
- En el **aprendizaje supervisado**, la **clasificación** es el proceso de identificar a cuál de un conjunto de clases pertenece una **nueva observación** (fase de prueba), a partir de un conjunto de **datos de entrenamiento** que contiene observaciones cuya clase se conoce (fase de entrenamiento).



Clasificador general



Algoritmos de inferencia

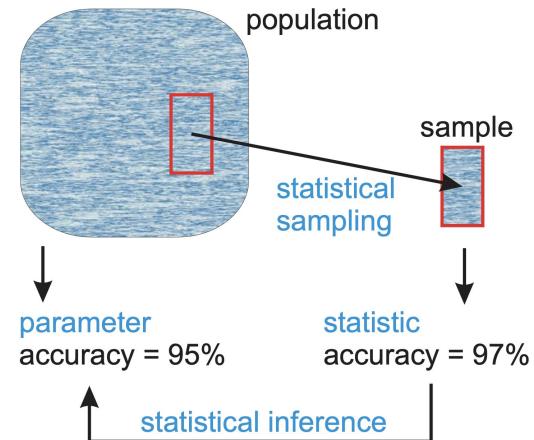


¿Hasta qué punto confiamos en el clasificador aprendido?

- Los clasificadores (tanto supervisados como no supervisados) se aprenden (entrenan) en un conjunto de **datos de entrenamiento finito**.
- Un **clasificador**, o modelo, aprendido debe probarse experimentalmente en una prueba diferente (datos de prueba).
- El rendimiento experimental sobre los **datos de prueba** es una aproximación al rendimiento en datos desconocidos – comprueba la capacidad de generalización del clasificador.
- Se necesita una función que evalúe experimentalmente el rendimiento del clasificador, e.g., su tasa de error, precisión, sensibilidad, especificidad.
 - Es necesario comparar los clasificadores experimentalmente.

La evaluación es una prueba de hipótesis

- La evaluación debe tratarse como una **prueba de hipótesis** en estadística.
- El valor del parámetro poblacional debe deducirse estadísticamente a partir de las estadísticas de la muestra (i.e., un conjunto de entrenamiento).



Partición de los datos

Uso de los datos: conjuntos de entrenamiento y de prueba

Problema: sólo se dispone de datos finitos y deben utilizarse tanto para el entrenamiento como para las pruebas.

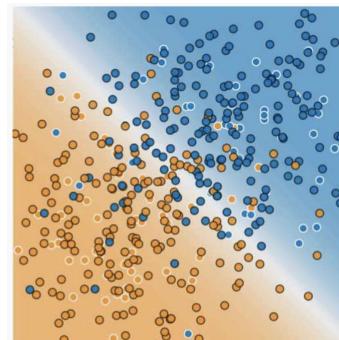
- Un mayor número de datos de entrenamiento mejora la generalización.
- Más datos de prueba dan una mejor estimación de la probabilidad de error de clasificación.
- **NUNCA** se debe evaluar el rendimiento de los clasificadores en función de los **datos de entrenamiento**: la conclusión tendría un sesgo optimista.

División de los datos

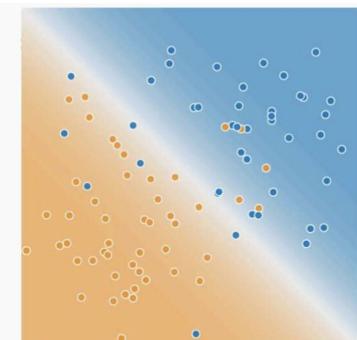
Partición (división) del conjunto finito de datos disponible en subconjuntos de entrenamiento/prueba:

- Hold out.
- Cross validation.
- Bootstrap.

Una vez finalizada la evaluación, todos los datos disponibles pueden utilizarse para entrenar el clasificador final.



Training Data



Test Data

Hold out method

- Los datos se dividen **aleatoriamente** en dos conjuntos independientes.
- El **conjunto de entrenamiento** (e.g., 2/3 de los datos) para la construcción del modelo estadístico, i.e., el aprendizaje del clasificador.
 - Generalmente la proporción de los datos es mayor al conjunto de prueba.
- El **conjunto de prueba** (e.g., 1/3 de los datos) se utiliza para estimar la precisión del clasificador.

DATASET COMPLETO

1	2	3	4	5	6	7	8	9	10	11	12
---	---	---	---	---	---	---	---	---	----	----	----

TRAIN

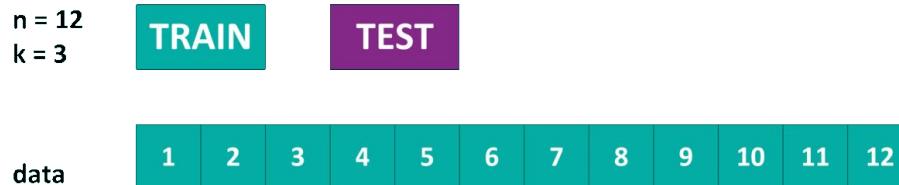
9	10	3	7	1	12	2	6
---	----	---	---	---	----	---	---

TEST

8	4	5	11
---	---	---	----

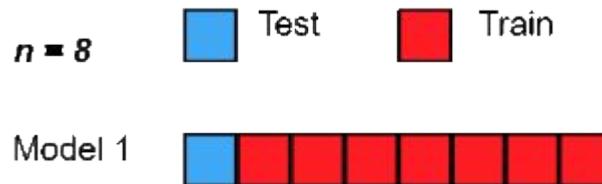
K-fold cross validation

- El **conjunto de entrenamiento** se divide **aleatoriamente** en k conjuntos disjuntos de igual tamaño en los que cada parte tiene aproximadamente la misma distribución de clases.
- El clasificador se evalúa k veces, cada vez con un conjunto diferente que se utiliza como **conjunto de prueba**.
- El rendimiento del clasificador es la media de estos k conjuntos.



Leave-one-out

- Un caso especial de validación cruzada k -fold con $k = n$, donde n es el número total de muestras del conjunto de datos.
 - Se realizan n experimentos utilizando $n - 1$ muestras para el entrenamiento y la muestra restante para las pruebas.
- Es bastante costosa desde el punto de vista computacional.



Métricas de evaluación

Retomando el *accuracy*

- La **exactitud** es el porcentaje de clasificaciones correctas.
- La **tasa de error** es el porcentaje de clasificaciones incorrectas.
- $Accuracy = 1 - Error\ rate.$

Problemas con estas métricas:

- Asume costes iguales para la clasificación errónea.
- Supone una distribución de clases relativamente uniforme (e.g., 0.5% de pacientes con una determinada enfermedad).

Se pueden derivar otras métricas de la matriz de confusión.

Matriz de confusión (tipos de errores)

- Una matriz de confusión, o matriz de error, es un diseño de tabla específico que permite visualizar el rendimiento de un modelo de clasificación.

		Predicted	
		Positive	Negative
Actual	Positive	TP	FN (error type I)
	Negative	FP (error type II)	TN

El primer tipo de error es **el rechazo** de una hipótesis nula verdadera.

El segundo es **el NO rechazo** de una hipótesis nula falsa.

Como ejemplo, un error de tipo I corresponde a condenar a un acusado inocente; mientras que un tipo II corresponde a absolver a un criminal.

Matriz de confusión (caso binario)

		Predicted		
		Positive	Negative	
Actual	Positive	True positive (TP)	False negative (FN)	Sensitivity
	Negative	False positive (FP)	True negative (TN)	Specificity
		Precision		F-measure

- Sensitivity, recall, o true positive rate (TPR):

$$\text{TPR} = \frac{\text{TP}}{\text{P}} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

- Specificity o true negative rate (TNR):

$$\text{TNR} = \frac{\text{TN}}{\text{N}} = \frac{\text{TN}}{\text{TN} + \text{FP}}$$

- Precision o positive predictive value (PPV):

$$\text{PPV} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

- Accuracy (ACC):

$$\text{ACC} = \frac{\text{TP} + \text{TN}}{\text{P} + \text{N}} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

- F1 score es la media armónica entre precision and sensitivity:

$$F_1 = 2 \cdot \frac{\text{PPV} \cdot \text{TPR}}{\text{PPV} + \text{TPR}} = \frac{2\text{TP}}{2\text{TP} + \text{FP} + \text{FN}}$$

Costes desiguales de las decisiones

- **Diagnóstico médico:** El coste de una indicación falsa de cáncer de mama en el cribado de la población es menor que el coste de pasar por alto una enfermedad verdadera.
- **Defensa contra misiles aéreos:** El coste de no detectar un ataque real es mucho mayor que el de una falsa alarma.

Problema de la distribución de clases desconocida

En muchas circunstancias, se desconoce la distribución de clases, e.g., un filtro de spam de correo electrónico. Los modelos estadísticos deben aprenderse de antemano.

- Diagnóstico médico: 95 % sano, 5 % enfermedad.
- Comercio electrónico: el 99 % no compra, el 1 % compra.
- Seguridad: el 99.999 % de los ciudadanos no son terroristas.

Una situación similar ocurre con los clasificadores multiclas. La clase mayoritaria puede acertar el 99 %, pero es inútil.

Dealing with the imbalance: sampling

Construir un conjunto de entrenamiento equilibrado para entrenar el clasificador.

- Seleccione aleatoriamente el número deseado de casos de clase minoritaria.
- Añada el mismo número de casos de clase mayoritaria seleccionados aleatoriamente.

Construya un conjunto de prueba equilibrado (diferente del conjunto de entrenamiento) para probar el clasificador.

Dealing with the imbalance: augmentation

Construir un conjunto de entrenamiento equilibrado para entrenar el clasificador.

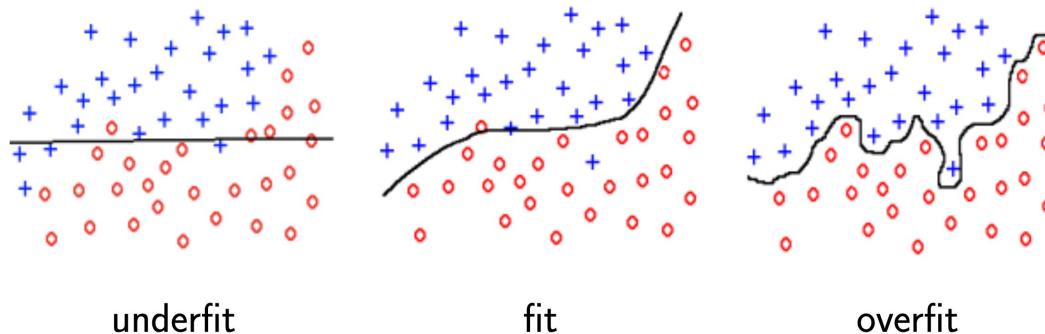
- Seleccione el número deseado de instancias de clase mayoritaria.
- Añada el mismo número de casos sintéticos de clases minoritarias.

Construya un conjunto de prueba equilibrado (**sin incluir datos sintéticos**) para probar el clasificador.

¿Es suficiente una
métrica para evaluar
el rendimiento de un
clasificador?

Riesgo de sobreajuste

- **Aprender** de los datos de entrenamiento con demasiada precisión suele dar lugar a malos resultados de clasificación en nuevos datos.
- ¡El clasificador debe tener la capacidad de **generalizar**!



¿Preguntas?

hussein@cicese.mx

